Sesi 5 GSLC Deep Learning

Nama: Justin Christian Kenan
NIM: 2802399463

Bagian A

1. **Efek Regularisasi pada Batch Normalization (Slide 6–8)**
   Slide 8 menyebutkan bahwa Batch Normalization "acts like mild regularization" dan "often eliminates the need for Dropout".
   - **Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.**
   - **Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.**

   Batch Normalization itu menormalisasikan aktivasi berdasarkan dari statistik mini-batch. Gunanya untuk mengurangi internal covariate shift, lalu mempercepat training, serta learning rate bisa digunakan lebih tinggi, dan karena sifatnya yang bertindak sebagai regularization yang dapat mencegah terjadinya overfitting atau bergantung pada representasi tertentu selama training pada model deep learning. Selama proses training, pada mean dan variance dihitung dari mini-batch yang membuat statistik normalisasi dapat berubah ubah antar batch yang ada. Efek regularization yang ditimbulkan batch normalization ini dapat menghilangkan kebutuhan terhadap dropout. Akan tetapi, tak berlaku pada kondisi overfitting yang masih kuat, maka dropout masih tetap diperlukan. Mini-batch yang sangat kecil juga membuat statistik terlalu noisy sehingga dapat menghasilkan estimasi statistik yang kurang stabil, jadi penggunaan Batch Normalization ini perlu untuk disesuaikan dengan konfigurasi trainingnya.

2. **Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)**
   Mengapa penambahan kedalaman lapisan pada plain CNN (tanpa sambungan residual) justru menurunkan akurasi pelatihan (degradation problem), padahal secara teoritis representasi model yang lebih dalam minimal dapat menyamai model dangkal via fungsi identitas (identity mapping)?
   - **Jelaskan bagaimana skip connection mengubah formulasi aliran gradien saat propagasi balik (backpropagation).**
   - **Hubungkan mekanisme tersebut dengan mitigasi fenomena vanishing gradient yang telah dibahas pada Sesi 02.**

   Deep network degradation dapat terjadi ketika network yang lebih dalam akan memberikan dan menghasilkan performa yang lebih buruk karena adanya faktor gradient vanishing atau gradient explosion dan juga information loss across layers. Serta semakin dalam network akan semakin sulit untuk di training dan memperkenalkan residual learning framework untuk mempermudah optimisasi deep network. Skip connection akan menambahkan input langsung ke output suatu blok pada residual block, alhasil gradient memiliki jalur tambahan untuk mengalir ketika

proses backpropagation dilakukan. Block tersebut mempelajari fungsi residual seperti (f(x)) dan kemudian menghasilkan (y = F(x) + x), maka network dapat mempelajari perubahan terhadap input dan tak harus mempelajari seluruh transformasi dari awal.

3. **Feature Extraction vs. Fine-Tuning (Slide 14–16)**
   Bandingkan pendekatan Feature Extraction (membekukan backbone) dengan FineTuning (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi:
   - **Jumlah parameter yang diperbarui (trainable parameters).**
   - **Kebutuhan volume data latih.**
   - **Beban komputasi dan memori per epoch.**
   - **Risiko rusaknya fitur representasi bawaan (destructive gradient updates). Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.**

   Transfer learning menggunakan model yang telah dilatih pada dataset besar seperti ImageNet dan representasi tersebut digunakan untuk dataset baru yang lebih kecil. Transfer learning memanfaatkan pengetahuan dari source domain atau task untuk membantu pembelajaran pada target domain yang relevan ketika data target terbatas. Feature extraction membekukan seluruh pretrained layers dan hanya classifier head yang diganti serta di training. Lalu pada fine tuning, pretrained weight tetap digunakan tetapi deep layer nya dibuka secara bertahap dengan learning rate yang lebih rendah. Fitur yang digunakan pada layer awal cenderung lebih general dan fitur pada layer yang lebih tinggi menjadi semakin spesifik terhadap task, yang membuat transferability dapat berbeda antar layer. Maka feature extraction membutuhkan lebih sedikit parameter dan compute, sedangkan fine tuning memberikan kemampuan adaptasi yang lebih besar tetapi terdapat risiko mengubah representasi pretrained, yang dimana feature extraction menjadi baseline pada data yang terbatas dan fine tuning dipilih ketika adaptasi domain diperlukan serta data mencukupi.

4. **Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)**
   - **Jelaskan pertimbangan metodologis mengapa pipeline data augmentation hanya diaktifkan pada train set dan harus dinonaktifkan pada validation/test set.**
   - **Berikan satu contoh teknik transformasi citra yang tidak layak digunakan untuk klasifikasi ras hewan peliharaan (pet breeds), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label.**

   Data augmentation diterapkan pada train set untuk menciptakan sebuah variasi tambahan serta meningkatkan generalisasi model yang best case nya menggunakan dataset berukuran kecil. Augmentation harus dinonaktifkan pada validation dan test karena kedua set itu berguna untuk mengukur performa pada data yang tak dimodifikasi secara random. Hasil pengukuran akan berubah antar run dan tidak merepresentasikan performa model secara konsisten. Invariansi semantik label juga harus dipertahankan oleh transformasi seperti perubahan visual tidak boleh mengubah

kelas sebenarnya. Transformasi yang tak layak untuk klasifikasi pet breeds itu seperti rotasi ekstrem hingga objek menjadi terbalik karena orientasi yang sangat tak natural dapat menghilangkan atau mengubah karakteristik visual penting yang digunakan untuk mengenali ras hewan dari sebuah foto. Sedangkan horizontal flip (rotasi ringan) yang termasuk teknik augmentation umum, harus menambah variasi visual tanpa mengubah sebuah makna atau identitas label gambar.

5. **Mitigasi Catastrophic Forgetting (Slide 28–29)**
   Slide 28 mengingatkan potensi terjadinya catastrophic forgetting apabila proses adaptasi model berlangsung terlalu agresif.
   - **Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.**
   - **Jelaskan dua strategi mitigasi konkret (misalnya differential learning rate, gradual unfreezing, atau linear warmup) beserta alasan teoritis mengapa strategi tersebut efektif.**

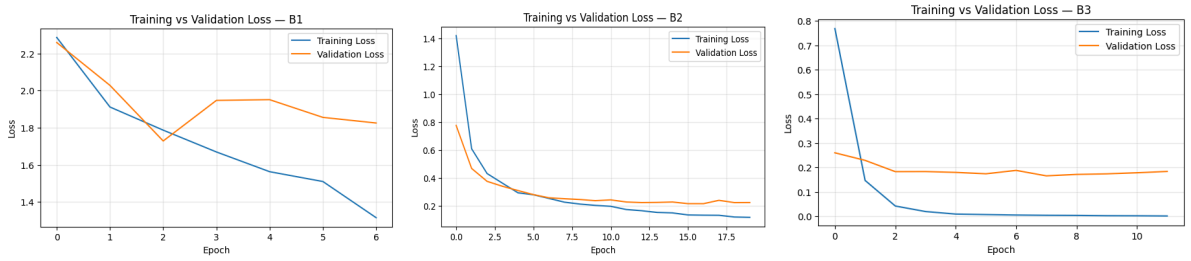
   Ketika proses adaptasi pretrained model terlalu agresif yang membuat bobot yang sebelumnya menyimpan representasi berguna menjadi berubah terlalu besar untuk menyesuaikan target dataset akan terjadi catastrophic forgetting. Apabila terjadi, model dapat menjadi lebih sesuai terhadap data baru dan akan kehilangan sebagian representasi yang diperoleh dari dataset. Strategi pertama itu adalah differential learning rate yang memberikan learning rate lebih kecil pada backbone serta lebih besar pada classifier. Akibatnya, perubahan yang terjadi pada backbone menjadi gradual yang merepresentasikan pretrained lebih terlindungi dan classifier tetap beradaptasi cepat. Strategi kedua itu gradual unfreezing yang membuka layer dengan bertahap dan tidak membuka langsung untuk memperbarui seluruh backbone. Terkontrolnya adaptasi dan perubahan pada representasi pretrained dapat diamati sebelum layer tambahan dibuka. Kedua strategi ini akan mengurangi risiko destructive updates selama domain adaptation.

Bagian C

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran Sajikan tabel komparatif menyeluruh yang merangkum kondisi B1 hingga B5 (meliputi: strategi, jumlah trainable parameters, learning rate, epoch konvergen, waktu pelatihan, akurasi validasi, dan Macro F1 test). Lengkapi dengan grafik komparatif kurva training loss vs. validation loss untuk kondisi B1, B2, dan B3.

experiment	strategy	trainable_parameters	learning_rate	converged_epoch	training_time_minutes	best_val_loss	val_accuracy_at_best	test_accuracy	test_macro_f1
B1	From Scratch	11181642	1e-3	7	1.3388	1.7282	0.4100	0.3767	0.3380
B2	Feature Extraction	5130	1e-3 (fc)	20	3.2917	0.2164	0.9233	0.9400	0.9402
B3	Progressive Fine-Tuning	8398858	1e-4 (layer4), 1e-3 (fc)	12	2.0380	0.1659	0.9500	0.9500	**0.9497**
B4_No_Aug	B3 + without augmentation	8398858	1e-4 (layer4), 1e-3 (fc)	12	2.1085	0.1659	0.9500	0.9500	**0.9497**
B4_With_Aug	B3 + with augmentation	8398858	1e-4 (layer4), 1e-3 (fc)	12	3.1951	0.1727	0.9333	0.9467	0.9466
B5_MobileNetV3_Small	Pretrained + B3 strategy + without augmentation	657546	1e-4 (last feature block), 1e-3 (classifier)	8	1.3874	0.3098	0.8967	0.9067	0.9074

Tabel berikut menunjukkan B1 yang Resnet-18 mempelajari fitur fitur visual dari bobot random memiliki performa terendah (nilai macro F-1). Lalu pada B2 terdapat peningkatan yang cukup baik dan signifikan. Ditambah B3 dan B4 meraih nilai performa tertinggi dengan skor makro F-1 sebesar 0.9497, kedua nilai mereka sama karena menggunakan konfigurasi yang sama yaitu B3 tanpa ditambah dengan augmentasi melalui fine tuning pada layer terakhir dan classifier. Tapi pada B4 membuktikan bahwa augmentasi tak selalu menghasilkan nilai yang paling terbaik dan meningkat(walau berbeda sedikit dari nilai yang paling tinggi). Terakhir, B5 itu cukup bagus hasilnya tapi masih tak bisa menyaingi model ResNet-18 yang dimodifikasi.



B1: Validation loss terdapat peningkatan setelah epoch ke 2, akan tetapi Training loss mengalami penurunan, jadi ada indikasi overfitting yang generalisasinya masih terbatas.

B2: Training loss dan Validation loss mengalami penurunan yang curam semenjak epoch awal lalu setelah turunan itu muncul kestabilan. Jadi, walau backbone di freeze tetapi model pretrained ini dapat belajar mengklasifikasikan dengan baik dan terindikasi generalisasi yang relatif baik.
B3: Training loss terlihat jelas mendekati 0 dan Validation loss menurun pada epoch awal dan menjaga kestabilannya hingga ada sedikit peningkatan. B3 terindikasi overfitting ringan walau modelnya punya performa yang cukup tinggi.

C2. Pembahasan Analisis Komparatif Analisis fenomena empiris yang muncul dari data Anda dengan mengaitkannya pada konsep Slide 10–12, 16, 20, dan 28:

- **Mengapa terjadi disparitas performa yang tajam antara pelatihan dari nol (B1) dengan paradigma transfer learning (B2 & B3)?**
  ResNet-18 yang dilatih dari nol (from scratch) yaitu B1 memberikan validation accuracy sebesar 0.41 dan test macro F1 score sebesar 0.338 berbanding terbalik dengan ResNet-18 yang melalui feature extraction yang validation accuracynya tembus hingga 0.9233 dan F1 score sebesar 0.9422, ditambah juga B3 menggunakan ResNet-18 yang di fine tuning dapat mencapai validation accuracy sebesar 0.95 dan macro F1 score nya 0.9497. Disparitas yang terjadi ini terjadi karena B1 itu trainingnya menggunakan bobot yang random, maka harus mempelajari representasi visual datasetnya dari awal dengan jumlah data yang terbatas. Berbeda dengan B2 dan B3 yang memanfaatkan bobot pretrained ImageNet yang sudah mempelajari representasi visual terlebih dahulu seperti bentuk, tekstur, tepi, otomatis tak banyak membutuhkan pembelajaran dari data targetnya. Residual connection seperti ResNet ini yang membantu aliran informasi dan gradien pada deep network, tak pasti akan menjadi sebuah kunci untuk menghasilkan performa yang tinggi, tetapi pemanfaatan representasi pretrained juga menjadi salah satu supportnya untuk menghasilkan performa yang tinggi.
- **Bagaimana trade-off performa vs. stabilitas antara feature extraction murni dan finetuning bertahap pada volume data terbatas yang Anda miliki?**
  Fine tuning pada B3 memang menghasilkan performa yang sedikit lebih tinggi dibandingkan B2 (feature extraction), terlihat pada macro F1 score meningkat dari sebesar 0.9402 (B2) menjadi 0.9497 (B3), akan tetapi untuk penggunaan parameter B2 jauh lebih efisien hanya dengan menggunakan 5.130 parameter, jauh dibandingkan degan B3 menggunakan 8.398.858 parameter. Ditambah apabila melihat grafik training loss dan validation loss pada B2 yang menurun tetapi tetap stabil saat dibawah berbeda dengan B3 yang grafik training loss nya sudah mendekati nol dan validation loss yang bertahan sekitar 0.17 hingga 0.19 yang terindikasi overfitting yang lebih besar. Jadi, B2 (ResNet-18 yang menggunakan feature extraction) lebih unggul dibanding B3 (ResNet-18 yang menggunakan fine tuning) apabila dilihat dari efisiensinya dan kestabilannya pada proses training, lalu dengan pendekatan seperti B2 ini cocok dengan data berlabel dan sumber daya komputasi terbatas. Maka, strategi yang dipilih harus dipertimbangkan kesesuaian fitur pretrained dengan data target dan risiko overfittingnya.

- **Sejauh mana peran augmentasi (B4) dalam meredam overfitting (perhatikan celah selisih akurasi data latih terhadap data validasi)?**
  Augmentasi berfungsi untuk meregularisasikan dengan menghasilkan variasi gambar selama training dan transformasi yang dilakukan seperti membalikan gambar secara horizontal, rotasi, dan merubah warna yang ditujukan untuk membantu model mempelajari berbagai jenis varian gambar lainnya agar tidak ketergantungan pada karakteristik gambar yang sudah ada (overfitting). Sayangnya peran augmentasi data pada B4 dalam meredam overfitting masih kurang berdampak dan belum memberikan peningkatan generalisasi, karena hasil B4 yang menggunakan augmentasi data tak meningkatkan performa, terlihat pada hasil B4 tanpa augmentasi dapat meraih validation accuracy sebesar 0.95 dan test macro F1 score sebesar 0.9497, lalu ketika diberikan augmentasi data pada B4 terjadi penurunan validation accuracy menjadi 0.9333 dan macro F1 score menjadi 0.9466. Tetapi bukan berarti penggunaan data augmentation akan selalu merugikan.

experiment	train_accuracy_eval_transform	validation_accuracy_at_best	generalization_gap
B4_No_Aug	1.0000	0.9500	0.0500
B4_With_Aug	0.9957	0.9333	0.0624

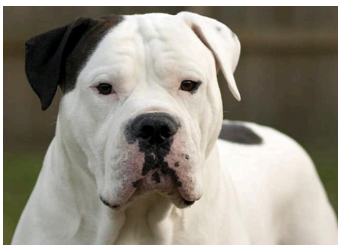
Pada tabel generalization gap ini menggunakan rumus Generalization Gap = Train Accuracy - Validation Accuracy. Hasilnya menunjukkan B4 tanpa augmentasi memiliki generalization gap sebesar 0.05 atau 5% dan B4 dengan menggunakan augmentasi sebesar 0.0624 atau 6.24%, maka augmentasi yang digunakan belum dapat memperkecil kesenjangan antara performa data yang di train dan data yang divalidasi.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)

Tampilkan 5 s.d. 8 sampel citra dari test set yang salah diprediksi oleh model terbaik Anda. Untuk setiap sampel, sertakan:

- **Citra input bersangkutan.**
- **Label aktual (ground truth).**
- **Prediksi model beserta probabilitas keyakinan (confidence score).**
- **Hipotesis penyebab kesalahan (misalnya: ambiguitas visual antar ras, sudut pengambilan ekstrem, oklusi, pencahayaan buruk, atau bias latar belakang).**



Ground truth	Prediction	Confidence	Hypothesis (Penyebab kesalahan)
american pit bull terrier	american bulldog	0.9847	 Kepala american pitbull terrier dengan american bulldog terlihat struktur yang mirip seperti strukturnya, matanya, hidung hingga moncong ke mulut. Keyakinan model tak akan selalu pasti tepat mengklasifikasikan ras hewan tersebut.
Abyssinian	Bengal	0.5100	 Pada foto yang misklasifikasi sebenarnya kurang jelas karena posisi terbalik dan sedikit terpotong, Hanya warna yang cukup mirip, hal ini membuat model sulit mengenali pola wajah, maka confidence yang dihasilkan kecil.

american bulldog	beagle	0.6091	 Anakan american bulldog dengan anak beagle masih belum terlalu ada pembeda dari fisiknya secara signifikan, baru terlihat saat keduanya dewasa yang sudah berkembang, maka model berpotensi melihat corak dan warna bulu kedua ras hewan tersebut.
Abyssinian	Bengal	0.9196	 Walau nilai confidence nya tinggi hingga mencapai 91% akan tetapi model masih salah mengklasifikasikan, hal ini terjadi karena adanya potensi model kesulitan melihat gambar tersebut, karena gambar yang diprediksi itu hanya menampilkan kepala kucingnya saja, sehingga model hanya menyamakan kedua ras kepala kucing tersebut.
american bulldog	basset hound	0.3388	 Foto yang diprediksi cukup terpotong, zoom, dan posisi yang tiduran sangat kurang jelas (angle buruk), hal ini membuat model kesulitan mengenali ras hewan tersebut menjadi keliru dan menghasilkan nilai confidence yang kecil
american pit bull terrier	boxer	0.7685	

			Foto yang benar benar buruk karena jelas terpotong hingga semua bagian benar benar tak utuh. Selain badan, wajah menjadi fitur penting yang digunakan model untuk mengenali dan mengklasifikasikan ras hewan tersebut. Maka model berpotensi melihat warna bulu kedua ras hewan tersebut hingga memberikan confidence yang cukup tinggi.
beagle	basset hound	0.6345	 Posisi hewan yang tiduran dan pengambilan foto dari jarak jauh, serta minimnya cahaya membuat model hanya melihatnya dari pola warna pada bulunya yang membuat kedua kelas tersebut tertukar.
boxer	american bulldog	0.8697	 Foto yang diprediksi terlalu dekat dan badan sama sekali tak terlihat mengakibatkan model hanya melihatnya dari mulut dan rahang yang lebar serta corak warnanya yang bisa ditemukan pada kedua ras hewan tersebut.

2 faktor yang mempengaruhi model dalam mengklasifikasikan ras hewan: kemiripan visual antar ras dan kualitas gambar yang tersedia (angle buruk, terpotong, zoom out, minim cahaya, dll)

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Berikan rekomendasi praktis bagi tim rekayasa industri: strategi pelatihan mana yang paling optimal untuk skenario data terbatas, lengkap dengan kondisi berlakunya (operational constraints). Sebutkan secara jujur limitasi dari studi Anda (misalnya: pengujian berbasis single seed, keterbatasan jumlah kelas, atau anggaran komputasi).

Bagi kasus tim rekayasa industri, strategi yang paling optimal untuk skenario data terbatas adalah menggunakan B3 yang menggunakan ResNet-18 di fine tuning karena menghasilkan performa klasifikasi terbaik pada dataset terbatas. Dengan memanfaatkan bobot pretrained ImageNet dan menyesuaikan layer terakhir dan classifier terhadap karakteristik dataset target, walau harus melakukan train dengan lebih banyak parameter. Lalu untuk B2 dengan menggunakan ResNet-18 yang diberi feature extraction juga menghasilkan hasil yang tak kalah jauh dibanding B3, B2 cocok untuk kondisi data dan waktu training terbatas dan harus

mengejar efisiensi karena B2 ini membekukan backbone dan hanya mengtrain 5.130 parameter berbanding jauh dengan B3. Apabila memori atau sumber daya terbatas menggunakan B5 dengan MobileNetV3-Small ini menjadi jalan, karena jumlah parameter lebih sedikit akan tetapi kurangnya di performa klasifikasi yang lebih rendah. Jika membahas augmentasi data sebenarnya tak direkomendasikan karena hasilnya yang membuat generalization gap yang tak mengecil, malah sebaliknya tanpa augmentasi data, generalization gap bisa mengecil. Maka untuk case ini augmentasi data belum dapat meningkatkan generalisasi.
Limitasi studi:
Keterbatasan jumlah kelas menjadi limitasi pertama karena hanya menggunakan 10 kelas hewan dari dataset ini yang dimanna hasilnya belum tentu berlaku pada seluruh ras hewan dan kondisi foto berbeda dari training data. Lalu dilanjutkan oleh adanya potensi overfitting yang terlihat pada grafik training loss di B3 yang mendekati nol dan validation loss nya cukup relatif stabil yang nilainya diatas training loss.

AI Disclosure Statement
ChatGPT dalam tugas ini digunakan sebagai alat bantu dalam memahami konsep Advanced CNNs dan Transfer Learning, memandu dalam membuat menyusun sintaksis code, lalu membantu melihat potensi kesalahan pada code, dan membantu menganalisis hasil dan menyusun laporan yang sesuai dengan output nyatanya, apa adanya tanpa ditambah atau dikurangi dan ditulis ulang sendiri. Semua yang dihasilkan oleh ChatGPT telah dibaca ulang agar sesuai dengan instruksi soal dan agar tidak keluar dari jalur.

Reference
Loffe. S, Szegedy. C. (2015). *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift.* Proceedings of the 32nd International Conference on Machine Learning (ICML).

He. K, Zhang. X, Ren. S , Sun. J. (2016). *Deep Residual Learning for Image Recognition.* Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

Yosinski. K, Clune. J, Bengio. Y, Lipson. H. (2014). *How Transferable Are Features in Deep Neural Networks?* Advances in Neural Information Processing Systems (NeurIPS).

Pan. S. J and Yang. Q. (2010). *A Survey on Transfer Learning*. IEEE Transactions on Knowledge and Data Engineering.